

PONTIA WORLD

RECONOCIMIENTO DE EMOCIONES

Sistema avanzado de análisis de datos para la detección y clasificación de emociones en parques temáticos.



Nuestro equipo

ANAMARÍA TURDA

Project Manager

Liderazgo del Proyecto, limpieza de datos con python, modelo relacional SQL, desarrollo ML e IA generativa.

INÉS BENITO

Miembro activo

Limpieza de datos con python, modelo relacional SQL, desarrollo ML e IA generativa.

IÑIGO UGIDOS

Miembro activo

Limpieza de datos con python, modelo relacional SQL, desarrollo ML e IA generativa.

WILLIAM GANEM

Miembro activo

Limpieza de datos con python, modelo relacional SQL, desarrollo ML e IA generativa.





Objetivos

OBJETIVO GENERAL

Analizar los datos generales generados en Pontia World para detectar patrones en las emociones y usar esa información para mejorar la experiencia de los clientes y la rentabilidad del negocio

OBJETIVOS ESPECÍFICOS

OBJETIVO 1

Desarrollar un proceso ETL completo utilizando Python y librerías como Pandas y Numpy para la limpieza de archivos JSON.

OBJETIVO 2

Diseñar e implementar un modelo de base de datos relacional en SQL que organice la información para facilitar consultas.

OBJETIVO 3

Desarrollar, entrenar y comparar diferentes modelos de ML/DL para clasificar emociones y predecir comportamientos. Acompañarlo de una propuesta de IA Generativa.

OBJETIVO 4

Generar un dashboard de insights para presentar los datos y conclusiones, cargando los datos en Power BI.

Metodología

PIPELINE LIMPIEZA DE DATOS

Partiendo de archivos JSON, se identificaron y corrigieron diversos problemas de calidad:

- ★ **FORMATO DE DATOS**
Desglose de datos encapsulados en diccionarios y homogeneización de tablas.
- ★ **VALORES NEGATIVOS**
Tiempo de espera, costes y duraciones negativas transformados a valores positivos.
- ★ **ID VISITANTE INCONSISTENTE**
Se creó un nuevo campo id_visitante a partir de procedencia, duración y día de visita.
- ★ **VALORES EXTREMOS EN DURACIÓN**
Visitas con duración superior a 9 horas imputadas con la duración media de 350 minutos.
- ★ **VALORES ATÍPICOS EN COSTES**
Tickets con valores muy bajos revisados por tipo de entrada.



Número de visitantes por duración media (minutos)

Visitas

duration, redondeada

Visitas



Base de datos

PIPELINE PREPARACIÓN SQL

★ LIMPIEZA Y TRANSFORMACIÓN

Limpieza y transformación de datos para cargarlos en SQL.

★ SOLUCIÓN DE ERRORES TÉCNICOS

Solución de errores de codificación (utf-8 → latin1) + validación de tipos + problemas de carga de datos.

★ DEFINICIÓN DE REGLAS DE NEGOCIO

Definición de reglas de negocio para imputar valores anómalos (duración > 540min = 350 min, fast pass comprados con > 3 días de antelación = Pase rápido erróneo).

★ PREPARACIÓN FINAL

Uso de los CSVs para la realización de consultas/queries.

Modelo relacional

Modelo de datos

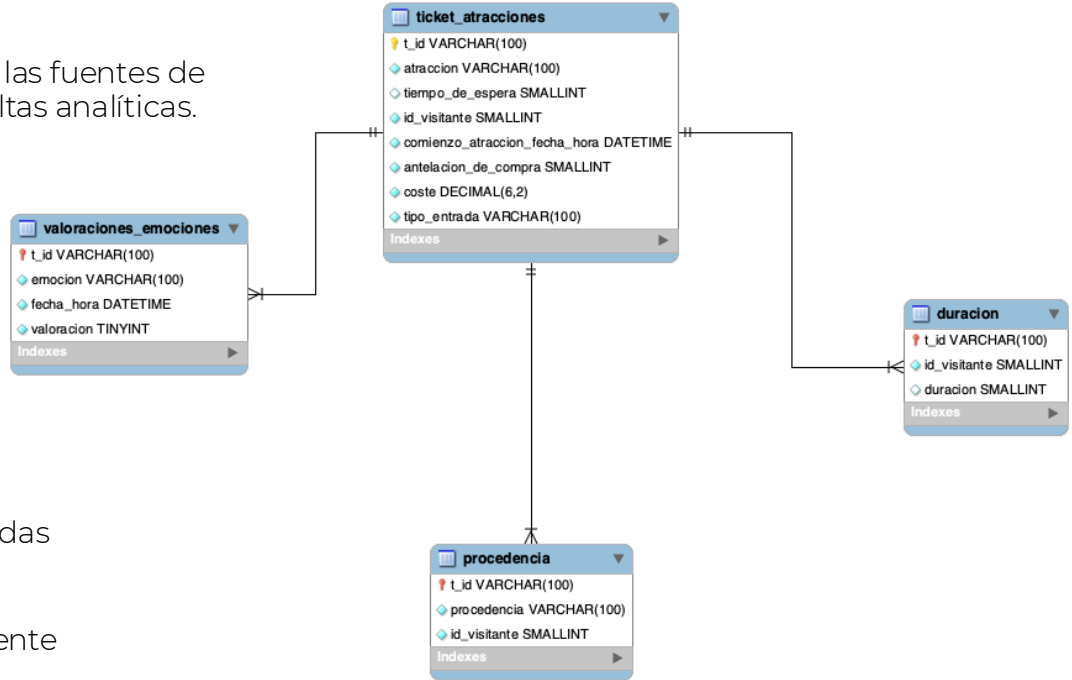
Se diseñó un modelo relacional que conecta las fuentes de datos y tablas principales para facilitar consultas analíticas.

Sistema Rank

Se implementó un sistema con RANK para manejar empates en los datos y obtener una mejor visión de conjunto.

Conclusiones

- ★ Los visitantes subían como máximo a 7 atracciones, y como mínimo a 1.
- ★ La emoción más fuerte es "feliz" para todas las atracciones.
- ★ Todas las atracciones tienen prácticamente la misma media de valoración (5/10).



Consultas destacadas

- ★ La mayoría de los visitantes (90,74%) solo se han subido a una atracción.
- ★ La media de valoraciones no varía significativamente por cada país.
- ★ Las entradas tienen el mismo precio independientemente de la antelación de su compra.
- ★ El tiempo de espera no afecta positiva o negativamente a las valoraciones.
- ★ El tiempo de espera es prácticamente igual para todas las atracciones.



Detección de emociones

OBJETIVO

Desarrollar un sistema que clasifique 7 emociones a partir de imágenes faciales 48×48 en escala de grises, usando el dataset de Pontia World.

ANGRY

DISGUST

FEAR

HAPPY

NEUTRAL

SURPRISE

PREPARACIÓN DE DATOS

- ✓ División: Train \approx 22.968, Val \approx 5.741, Test \approx 7.178 imágenes.
- ✓ Aumentación moderada (rotación, traslación, flip, zoom).
- ✓ Normalización: Rescalado a $[0,1]$.
- ✓ Class weights para equilibrar clases desbalanceadas.


MÉTRICAS PRINCIPALES Y CRITERIOS DE EVALUACIÓN

★ KPI principal — Macro-F1

Promedia el F1 por clase dando el mismo peso a cada emoción, crítico cuando hay desbalance de clases.

★ KPI de referencia — Accuracy

Sencilla de entender (aciertos/total), útil para una visión global pero puede enmascarar problemas en clases minoritarias.



DEL PREENTRENADO GENÉRICO AL CNN COMBINADO

★ FASE 0 – TRASFER LEARNING

Punto de partida con MobileNet. Resultado: ~48% accuracy. El mismatch de escala (48×48) y la falta de ajuste fino impidieron capitalizar el preentrenamiento.

★ FASE 1 – CNN PROPIA “SIMPLE”

Arquitectura secuencial básica sin nada contra el desbalanceo. Resultado: ~0,54 accuracy y 0,50 en macro-F1. Mejor que el preentrenado pero floja en clases minoritarias.

★ FASE 2 – CNN “PROFUNDA” Y ESTABLE


Mayor profundidad, augmentación moderada, class weights, BatchNorm y Dropout. Resultado: ~0,63 accuracy y ~0,61 macro F1. Mejora en equilibrio entre emociones.

★ FASE 3 – DE CLASIFICADOR A “BACKBONE + EMBEDDINGS”

CNN como extractor de embeddings con clasificador lineal y uno fino para el bloque difícil angry/fear/sad.

★ FASE 4 – ENSAMBLE SUAVE

Ensamble entre CNN y clasificador especializado con peso $\alpha=0,25$: 0,6454 accuracy y 0,6237 Macro-F1 en TEST (mejor rendimiento global).



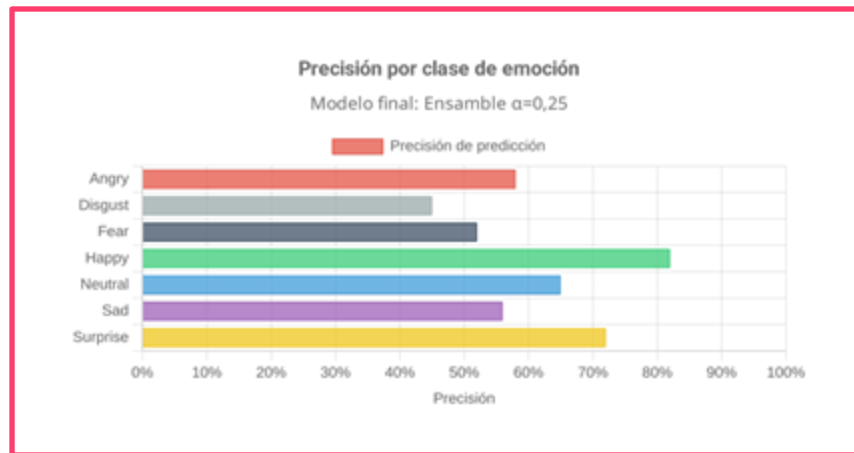
Conclusión y modelo final

FUNCIONAMIENTO DEL MODELO ELEGIDO

- 1 Recibe la imagen en tamaño pequeño y en blanco y negro (para quedarse con las formas y gestos importantes).
- 2 Una red (CNN) actúa como extractor de rasgos: cejas, ojos, comisuras, arrugas. De ahí saca un resumen numérico.
- 3 Se combinan dos opiniones independientes: generalista (probabilidad por emoción) y especialista (para casos confusos).
- 4 Fusión con peso fijo: 25% especialista / 75% generalista, dando más voz al generalista pero escuchando al especialista.
- 5 Se elige la emoción con mayor probabilidad y se muestra también un nivel de confianza.

LIMITACIONES Y RIESGOS

- ✓ Desbalanceo de clases (disgust muy escasa) que sesga el aprendizaje.
- ✓ Solapamiento semántico entre expresiones sutiles (fear vs sad/angry).
- ✓ Transfer learning genérico no adapta bien a imágenes 48x48.



Viabilidad de las métricas

★ SUPERACIÓN DEL NIVEL DE AZAR

El modelo del Proyecto Júpiter (64.54% Accuracy) supera significativamente el nivel de azar para 7 emociones (14.29% Accuracy), siendo aproximadamente 4.5 veces más preciso que una predicción aleatoria.

★ RENDIMIENTO COMPARATIVO CON HUMANOS (FER2013)

En el dataset FER2013, el rendimiento humano estimado es de ~65.5% Accuracy. El modelo del Proyecto Júpiter (64.54% Accuracy) se encuentra muy cerca de este baseline, demostrando una capacidad competitiva.

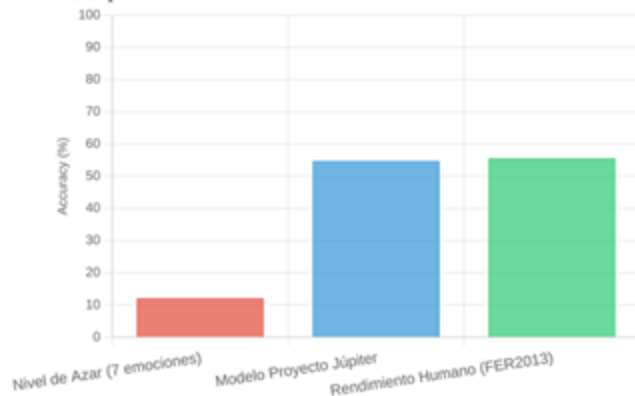
★ CONTEXTO DE COMPLEJIDAD

Estudios muestran que el rendimiento humano en tareas de reconocimiento de emociones puede variar (41%-72% Accuracy) y ser inferior en contextos más complejos o con mayor número de emociones.

★ VIABILIDAD Y POTENCIAL

Las métricas obtenidas demuestran que el modelo es viable y robusto para la clasificación de emociones, ofreciendo una base sólida para la toma de decisiones estratégicas en PontIA World.

Comparación de Rendimiento: Modelo vs. Azar vs. Humano





IA generativa

RESUMEN

★ PROBLEMA

Valoraciones bajas en atracciones (media de 5 sobre 10).

★ OBJETIVO

Mejorar la experiencia y valoraciones de los visitantes.

★ SOLUCIÓN

IA generativa para personalización de la experiencia en tiempo real.

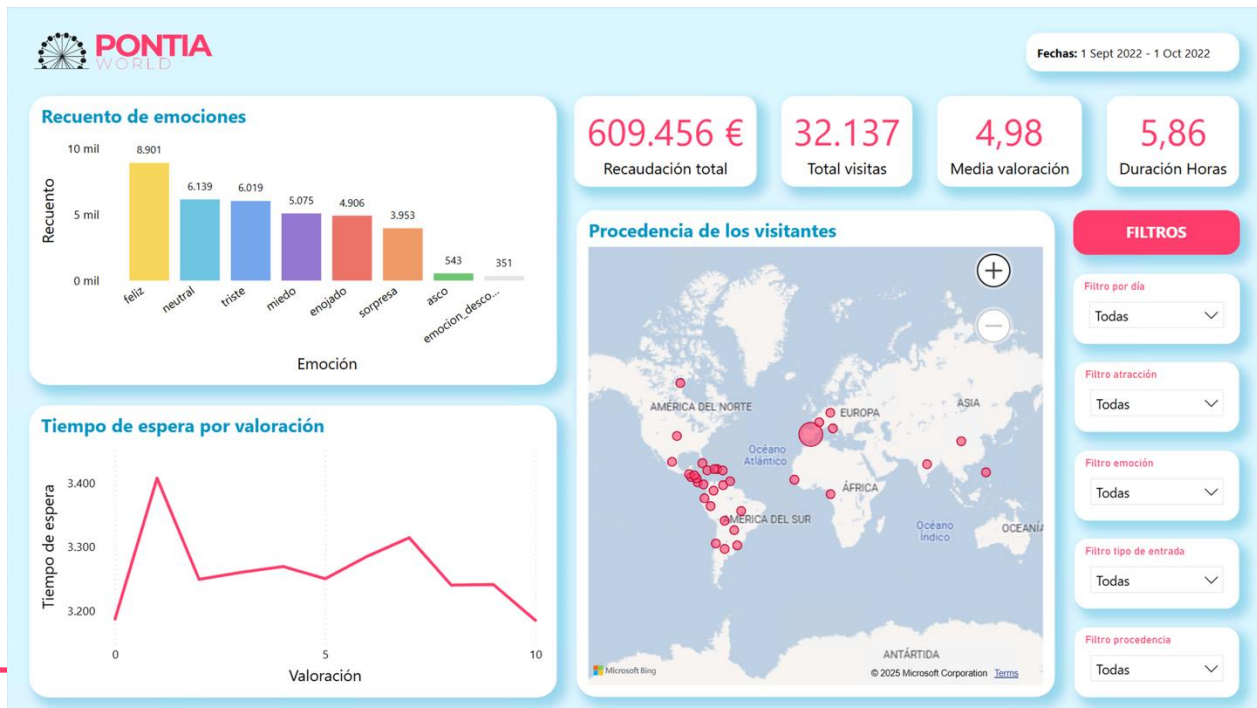
CASOS DE USO

- ✓ Itinerario personalizado con tiempos de espera en tiempo real.
- ✓ Chat para incidencias y dudas del usuario.
- ✓ Diseño adaptativo de experiencias basado en emociones.

BENEFICIOS ESPERADOS

- ✓ Fiabilidad y trazabilidad de datos automatizada.
- ✓ Mejora de valoraciones (objetivo: subir de 5-7 sobre 10).
- ✓ Propuesta de valor diferencial frente a competencia.

Dashboard interactivo





Conclusiones

XX
✓ XXX

XX
✓ XX

Trabajo a futuro

★ Tablas estáticas en SQL.

★ XX

★ XX

★ XX

★ XX



¡GRACIAS!



